Предсказание оттока студентов в LMS

Решение кейса ООО «Цифровое образование» (Цифриум)

Команда:
Антон Дудецкий
Виктор Морозов
Никита Мачульский
София Канюкова

April 21, 2026

Постановка задачи

Рассматривается множество пользователей $\mathcal{U} = \{u_1, u_2, \ldots, u_n\}$ и множество курсов $\mathcal{C} = \{c_1, c_2, \ldots, c_m\}$.
Базовый объект моделирования:

$$x_i = (u_i, c_i),$$

то есть конкретный пользователь на конкретном курсе.
Для каждого такого объекта строится вектор признаков

$$X_i \in \mathbb{R}^d,$$

который описывает курс, пользователя и его поведение в системе.
Целевая переменная:

$$Y_i = \mathbb{1}(\text{пользователь завершил модуль}).$$

Итоговая задача:

$$\hat{p}_i = P(Y_i = 1 \mid X_i).$$

Практический смысл: модель должна не просто предсказать класс, а оценить вероятность успешного завершения модуля.

Что именно предсказываем

Целевая переменная бинарная:

$$Y_i = \begin{cases} 1, & \text{если модуль завершён,} \\ 0, & \text{если пользователь выбыл.} \end{cases}$$

Таким образом, задача сводится к бинарной классификации.

Но в реальном использовании важен не только сам класс, а ещё и **уровень риска**. Поэтому модель должна выдавать вероятность:

$$\hat{p}_i \in [0, 1].$$

Чем меньше это значение, тем выше риск, что студент не дойдёт до конца модуля.

Это позволяет ранжировать студентов по риску и использовать прогноз для раннего вмешательства.

Объём данных

Размеры выборок:

$$N_{\text{train}} = 4927, \quad N_{\text{infer}} = 1785, \quad N_{\text{labeled}} = 4927$$

Пространство признаков:

$$d = 453$$

Особенность:

- высокая размерность признаков;
- необходимость агрессивного feature selection;
- риск переобучения и leakage.

Именно поэтому основной упор делался на:

- интерпретируемость признаков;
- проверку статистической значимости;
- методическую корректность постановки.

Почему задача не совсем стандартная

Обучение в данных устроено по модулям:

$$M1 \to M2 \to M3.$$

Здесь возникает эффект отбора:

$$P(Y = 1 \mid M2) \gg P(Y = 1 \mid M1).$$

Это означает, что до модуля $M2$ доходят уже не все, а в среднем более устойчивые и вовлечённые пользователи.

Во втором модуле мы видим уже не всю исходную популяцию, а "отфильтрованную" её часть. Это и есть **survivor bias**.

Чтобы учитывать этот эффект, в признаки добавляется номер модуля:

$$x_{\text{module}} \in \{1, 2, 3\}.$$

Это позволяет модели понимать, на каком этапе воронки находится пользователь.

Ограничение размеченных данных

Ключевое ограничение проекта связано с тем, что размеченная выборка существенно уже полного массива наблюдений.

Исход обучения известен только для сравнительно небольшой части студентов. Из-за этого в labeled-подмножестве снижается вариативность поведения, а ряд признаков теряет различающую способность.

Отсюда важный методический вывод:

- часть признаков, которые выглядели разумно на этапе препроцессинга, не прошла отбор на этапе EDA;
- это не означает, что такие признаки бесполезны вообще;
- на более широких и более вариативных размеченных данных они могут дать дополнительный сигнал.

Поэтому текущую модель и текущие выводы нужно рассматривать как консервативную оценку того, что удаётся извлечь из ограниченного labeled-среза.

Две основные линии исследования

В проекте были две взаимосвязанные задачи.

Первая линия — методическая. Нужно было понять, какие признаки вообще можно использовать для честного прогноза:

- собрать master-table;
- провести feature engineering;
- постепенно отсечь leakage;
- проверить гипотезы;
- выделить устойчивые и интерпретируемые сигналы.

Вторая линия — прикладная. По итогам EDA и моделирования нужно было сформулировать рекомендации:

- для тьюторов;
- для методистов;
- для раннего выявления студентов группы риска.

Общая схема решения

```
.
├── data/
│   ├── raw/
│   │   └── *.csv
│   ├── preprocessing/
│   │   ├── final_user_course_features.csv
│   │   ├── M1_M4.csv
│   │   ├── df_train.parquet
│   │   ├── df_infer.parquet
│   │   └── figures/
│   └── eda_output/
│       ├── *.png
│       └── predictions.parquet
├── notebooks/
│   ├── preprocessing.ipynb
│   ├── leave_only_M1_M4.ipynb
│   ├── target_preparation.ipynb
│   ├── eda.py
│   └── old_preprocessing.ipynb
├── scripts/
└── requirements.txt
```

Схема показывает полную структуру проекта: путь от сырых таблиц и агрегаций до гипотез, моделей и практических выводов.

Схема запуска

1. `notebooks/preprocessing.ipynb`
   Загружает сырые таблицы из `data/raw`, нормализует ключи и типы, строит базовую сущность `users_course_id`, агрегирует feature-блоки по пользователю, курсу и `user-course`, объединяет их в master-таблицу и добавляет time-based признаки.
2. `notebooks/leave_only_M1_M4.ipynb`
   Читает `data/preprocessing/final_user_course_features.csv`, оставляет участников программы по наличию `stats_m1_row_count` / `stats_m2_row_count` / `stats_m3_row_count`, проставляет `module` и сохраняет результат в `data/preprocessing/M1_M4.csv`.
3. `notebooks/target_preparation.ipynb`
   Читает `M1_M4.csv`, строит `target` для `M1` и `M2` через `stats_m1_module_completed_flag` / `stats_m2_module_completed_flag`, формирует `hist_m1_*` и `hist_m2_*`, удаляет leakage-признаки и сохраняет `data/preprocessing/df_train.parquet` и `data/preprocessing/df_infer.parquet`.
4. `notebooks/eda.py`
   Читает `df_train.parquet` и `df_infer.parquet`, выполняет EDA по размеченной выборке, проверяет гипотезы, сравнивает модели через `StratifiedGroupKFold`, обучает лучшую модель и сохраняет inference в `data/eda_output/predictions.parquet` вместе с графиками.

`notebooks/old_preprocessing.ipynb` присутствует в репозитории, но по текущему коду не входит в основную цепочку: он отдельно читает raw-таблицы и не формирует артефакты, которые затем читают следующие шаги.

Здесь показана техническая логика запуска пайплайна: загрузка витрин, EDA, гипотезный этап, сравнение моделей и переход к более строгой постановке.

Какие данные использовались

Данные в кейсе лежат не в одной таблице, а в наборе связанных сущностей. Основные источники:

- `users_courses` — пользователь на курсе;
- `users` — профиль пользователя;
- `lessons`, `lesson_tasks`, `groups` — структура курса;
- `user_lessons`, `user_trainings`, `user_answers` — учебное поведение;
- `wk_users_courses_actions` — действия внутри курса;
- `wk_media_view_sessions` — просмотры видео и трансляций;
- `stats_m1`–`stats_m4` — статусы и прогресс по модулям.

Поэтому первая часть проекта — это не обучение модели, а сборка корректной аналитической витрины на уровне

$$(user_id, course_id).$$

Схема сборки master-table

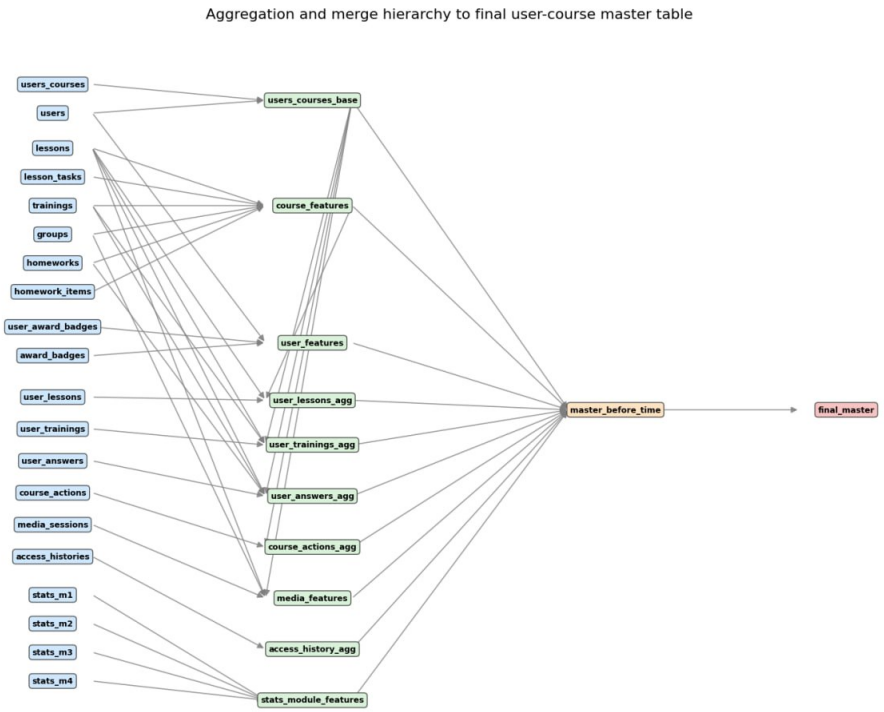

Master-table собирается не одним merge, а через несколько независимых блоков агрегации:

$$X_i = \bigcup_{k=1}^{K} f_k(\text{raw tables}).$$

Каждый блок берёт сырые таблицы и превращает их в компактный набор признаков нужной гранулярности.

Логика feature engineering

Весь feature engineering разбит на отдельные блоки:

- **users_courses_base** — базовая сущность;
- **course_features** — структура и сложность курса;
- **user_features** — свойства пользователя;
- **user_lessons** / **trainings** / **answers** — учебное поведение;
- **course_actions** / **media** — события и временные метрики;
- **stats_module** — таргет и история модулей.

Такой подход удобен по двум причинам:

- каждый блок можно разрабатывать и проверять отдельно;
- проще контролировать merge, пропуски и качество признаков.

Как устроен итоговый вектор признаков

Итоговый вектор признаков можно записать так:

$$X_i = \left[X_i^{\text{course}}, X_i^{\text{user}}, X_i^{\text{lesson}}, X_i^{\text{training}}, X_i^{\text{answers}}, X_i^{\text{actions}}, X_i^{\text{media}}\right].$$

То есть итоговая модель опирается не на один тип сигналов, а сразу на несколько:

- структуру курса;
- свойства пользователя;
- поведение в уроках и тренингах;
- поток действий и медиа-активность.

Именно такое разложение позволяет отделить **контекст курса** от **реального поведения студента**.

Почему EDA здесь был ключевым этапом

В этом проекте EDA использовался не только для описания данных, но и как инструмент методической фильтрации признаков.

Последовательность была такой:

- сначала формировался широкий пул потенциально полезных признаков;
- затем проверялась их статистическая состоятельность;
- после этого отдельно отсекались признаки с риском leakage;
- в финале оставались только те признаки, которые одновременно интерпретируемы, устойчивы и доступны в момент прогноза.

То есть EDA здесь был частью постановки задачи, а не декоративным этапом с графиками.

Базовая сущность: users_courses_base

В основе master-table лежит таблица `users_courses`. Она задаёт основную гранулярность: один пользователь на одном курсе.

Примеры признаков:

$$\text{uc_points_ratio} = \frac{\text{wk_points}}{\text{wk_max_points}},$$

$$\text{uc_tasks_per_viewable_lesson} = \frac{\text{wk_max_task_count}}{\text{wk_max_viewable_lessons}}.$$

Первая величина показывает, какую долю от максимума пользователь уже набрал. Вторая — какую учебную нагрузку в среднем несёт один доступный урок.

Также timestamp переводятся в числовые признаки в днях:

$$\text{uc_enrollment_age_days} = t_{\text{ref}} - t_{\text{created}},$$

$$\text{uc_official_start_delay_days} = t_{\text{official start}} - t_{\text{created}}.$$

Почему часть признаков пришлось отбросить

На этапе препроцессинга был сформирован достаточно широкий набор признаков, которые выглядели полезными с содержательной точки зрения.

Однако на этапе EDA часть из них пришлось исключить по двум причинам:

- либо они теряли различающую способность на ограниченном labeled-срезе;
- либо оказывались слишком близки к исходу обучения и создавали риск leakage.

Это касается, например, признаков, связанных с накопленным объёмом активности за весь модуль:

- число решённых задач;
- доля просмотренного контента;
- доля выполненных заданий.

Такие признаки могут быть полезны на более богатой разметке, но в текущей задаче делали бы постановку методически нечестной.

Почему leakage здесь особенно опасен

Если в модель попадают признаки, которые уже содержат информацию об исходе, качество оказывается искусственно завышенным.

Формально leakage возникает, если

$$x_j = f(Y, t > t_0),$$

то есть признак использует данные из будущего относительно момента прогноза.
Тогда возникает техническая связь

$$x_j \to Y,$$

которая не отражает реальную предсказательную силу.

Поэтому корректное требование такое:

$$X \perp \text{future outcome information}.$$

Иначе говоря, модель должна видеть только прошлое и текущее поведение, но не финальный результат обучения.

Hard leakage

Hard leakage — это признаки, которые почти напрямую кодируют ответ. Например:

- `wk_course_completed_at`
- `uc_has_completion_record`
- `uc_completion_delay_days`
- `uc_completed_flag`
- `uc_completed_without_points_flag`

Если такие признаки оставить, модель будет не прогнозировать исход, а фактически считывать его из данных.

Поэтому все такие столбцы удалялись ещё до обучения и интерпретации.

Soft leakage

Soft leakage — это признаки, которые формально не совпадают с таргетом, но слишком близки к нему по смыслу.

В эту группу попадали, например:

- `*_row_count`
- `*_lessons_viewed_count`
- `*_content_viewed_units`
- `*_final_tasks_solved_count`
- `*_interim_assessment_score`

Такие признаки вроде бы не содержат прямой метки завершения, но на практике оказываются слишком близки к итоговому статусу пользователя.

Исторические признаки

Отдельно контролировались исторические признаки по предыдущим модулям.

Чтобы не использовать информацию из будущего, применялись такие правила:

- `hist_m1_*` зануляются для строк $M1$;
- `hist_m2_*` зануляются для строк $M1$ и $M2$.

Почему это важно: история модуля может использоваться только там, где этот модуль уже действительно произошёл во времени.
Иначе модель начнёт получать информацию, которой в момент прогноза ещё не должно быть.

План гипотезного этапа

После первичного отбора признаков был проведён отдельный гипотезный этап.

Его цель состояла в том, чтобы ответить на шесть вопросов:

1. Есть ли survivor bias между модулями?
2. Связаны ли ранний старт и ранняя активность с completion?
3. Важнее ли качество выполнения, чем просто активность?
4. Влияет ли нагрузка курса на вероятность завершения?
5. Даёт ли timezone полезный сегментационный сигнал?
6. Какие блоки признаков дают основной предиктивный вклад?

Это позволило перейти от интуитивного отбора признаков к более формальному и интерпретируемому набору выводов.

H0. Survivor bias между модулями

Первая гипотеза состояла в том, что студенты, дошедшие до следующего модуля, уже представляют собой более устойчивую и мотивированную подвыборку.

Проверялось:

- различается ли completion rate между модулями;
- нужно ли сохранять `module_num` как обязательный контекстный признак.

Именно этот блок задаёт правильную интерпретацию всех следующих сравнений между $M1$ и $M2$.

H0. Target distribution by module

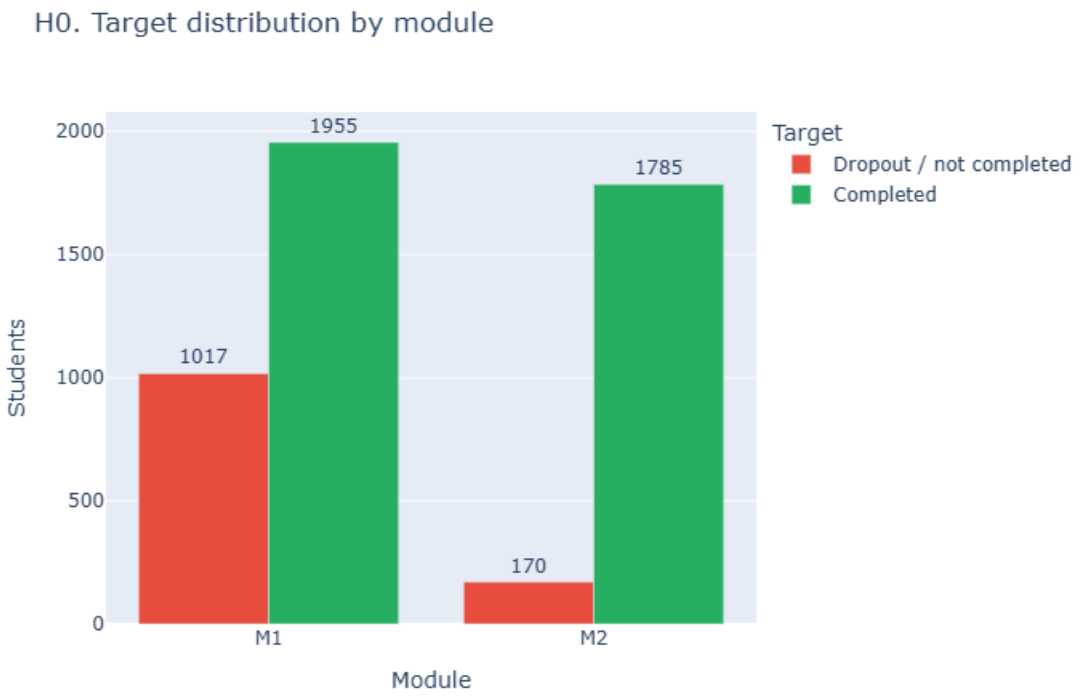

Распределение таргета по модулям показывает, что более поздние модули нельзя интерпретировать как просто “более успешные”: часть эффекта объясняется именно отбором студентов.

H0. Completion rate by module

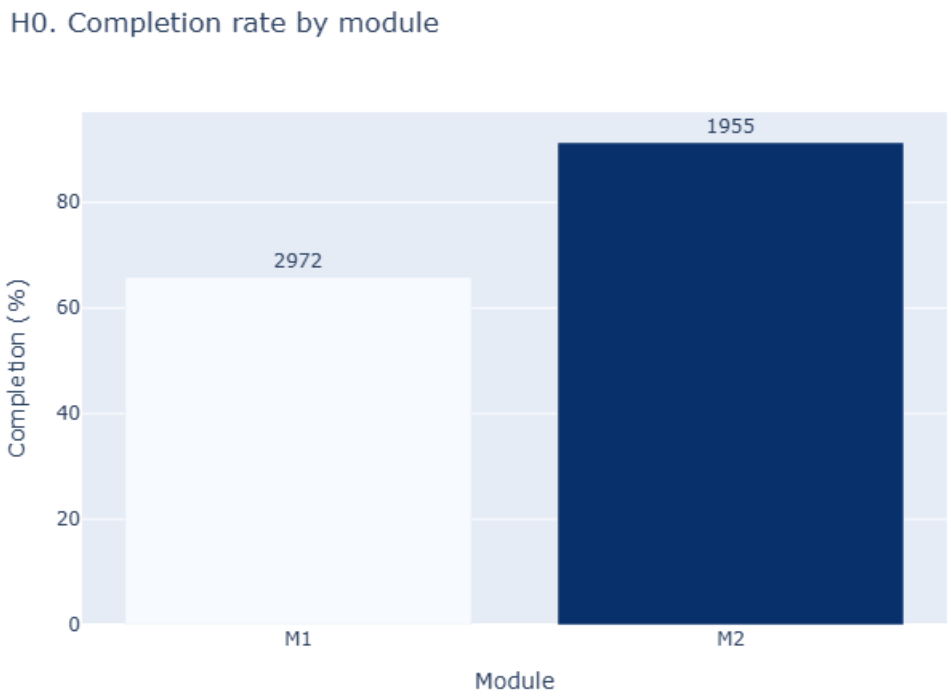

Различия completion rate между модулями подтверждают, что `module_num` должен учитываться как контекстный признак во всех последующих моделях и выводах.

H1. Ранний старт и ранняя активность

Гипотеза H1: студенты, которые раньше начинают курс и проявляют активность в первые 14 дней, чаще доходят до конца.

Проверялись два ключевых признака:

- `time_to_first_action_days`
- `answer_first_14d_count`

Это важная гипотеза не только для модели, но и для практики: если она подтверждается, значит ранний риск-скоринг вообще реализуем.

H1. Early behavior: boxplots

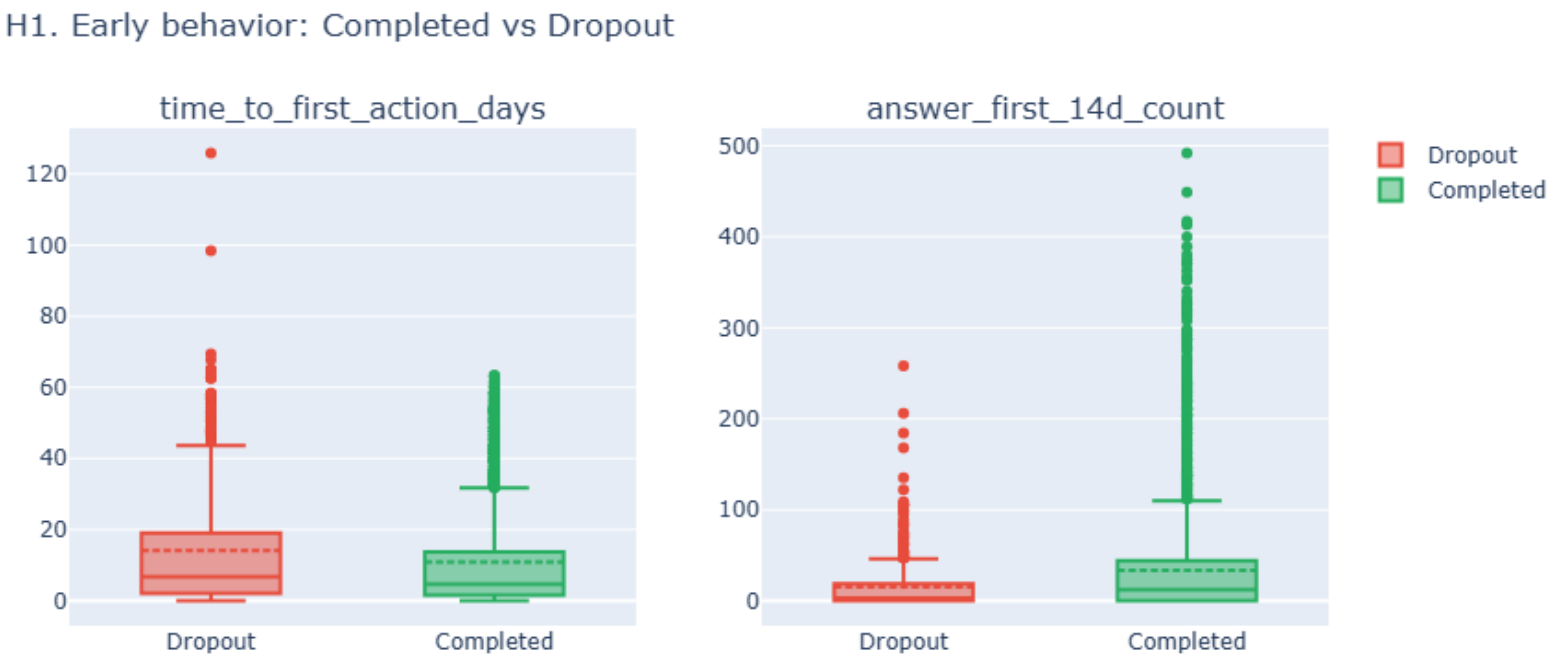

Распределения показывают, что у завершивших модуль пользователей старт раньше, а ранняя активность выше. Это подтверждает важность первых дней обучения.

H1. Раннее вовлечение как риск-сигнал

По результатам H1 можно сделать три вывода:

- поздний первый action связан с более высоким риском оттока;
- низкое число ответов в первые 14 дней тоже работает как ранний сигнал;
- уже на горизонте первых 1–2 недель можно выделять студентов группы риска.

Это один из самых practically useful результатов всего EDA.

H2. Активность против качества

Гипотеза H2: completion определяется не только количеством действий, но и качеством выполнения.

Проверялись:

- `answer_total_count` — сколько студент реально работает;
- `answer_solved_share` — насколько успешно он решает;
- `training_mark_mean` — качество прохождения тренировок.

Идея гипотезы: риск бывает не только у тех, кто не вовлёкся, но и у тех, кто работает, но систематически не справляется.

H2. Engagement vs Performance

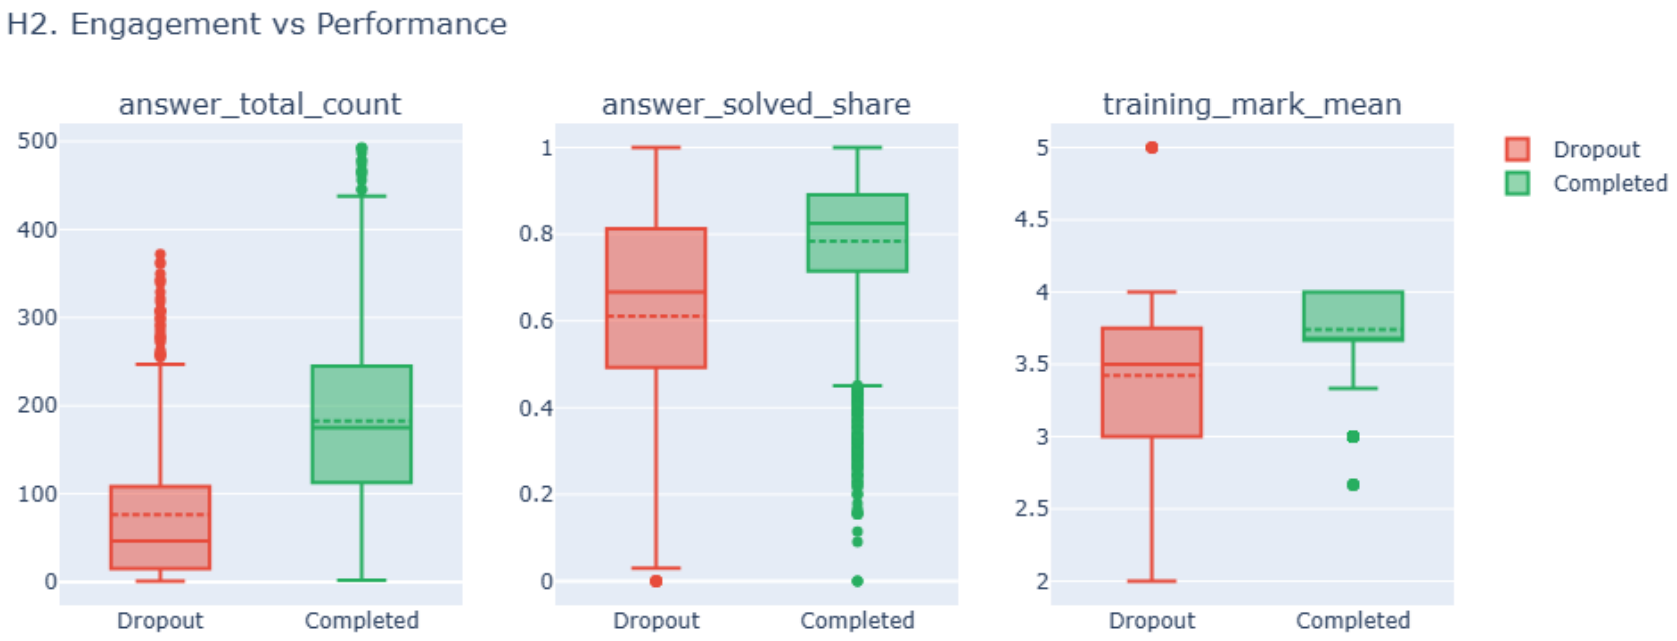

Сравнение completed и dropout показывает, что и объём активности, и качество выполнения несут самостоятельный сигнал.

H2. Activity vs quality

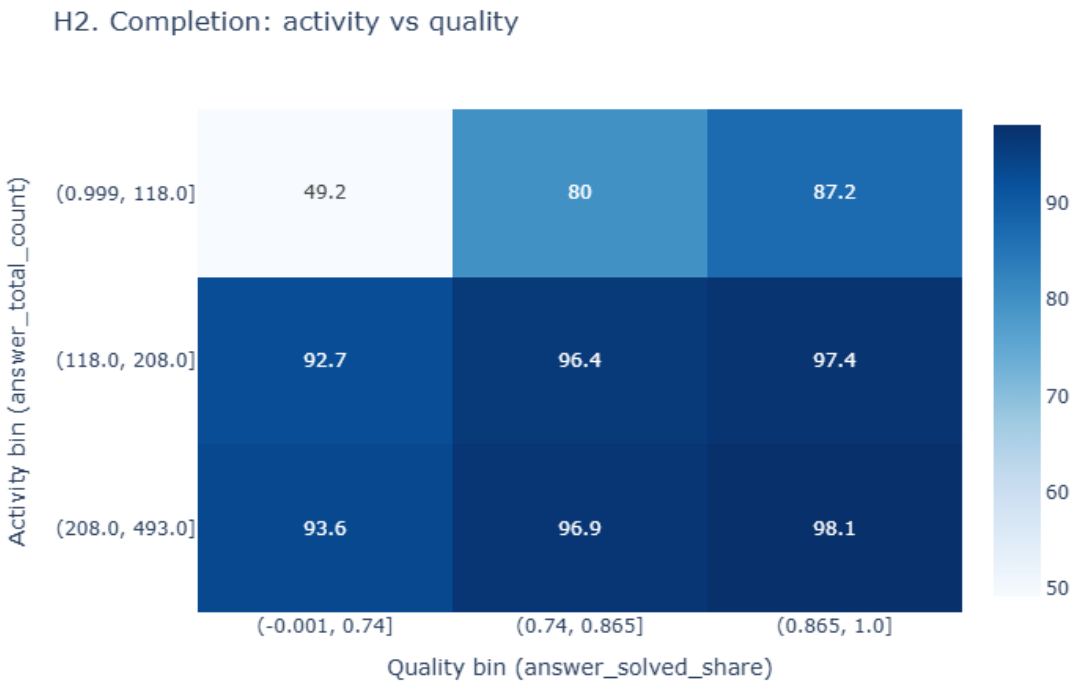

Тепловая карта помогает разделить разные сценарии риска: низкая активность и низкое качество дают разные управленческие интерпретации.

H2. Как это интерпретировать

По результатам H2 риск можно разделить как минимум на два типа:

- **low activity** — студент не включился в работу;
- **high activity + low quality** — студент включился, но не справляется.

Это важно для практики, потому что два этих случая требуют разных сценариев сопровождения.

H3. Гипотеза о нагрузке курса

Гипотеза H3: структура курса и плотность учебной нагрузки влияют на completion.

Проверялись course-level признаки:

- `course_tasks_per_lesson`
- `course_required_tasks_per_lesson`
- `course_unique_tasks_per_lesson`

Это уже не про поведение студента, а про саму учебную конструкцию курса.

Различия между курсами

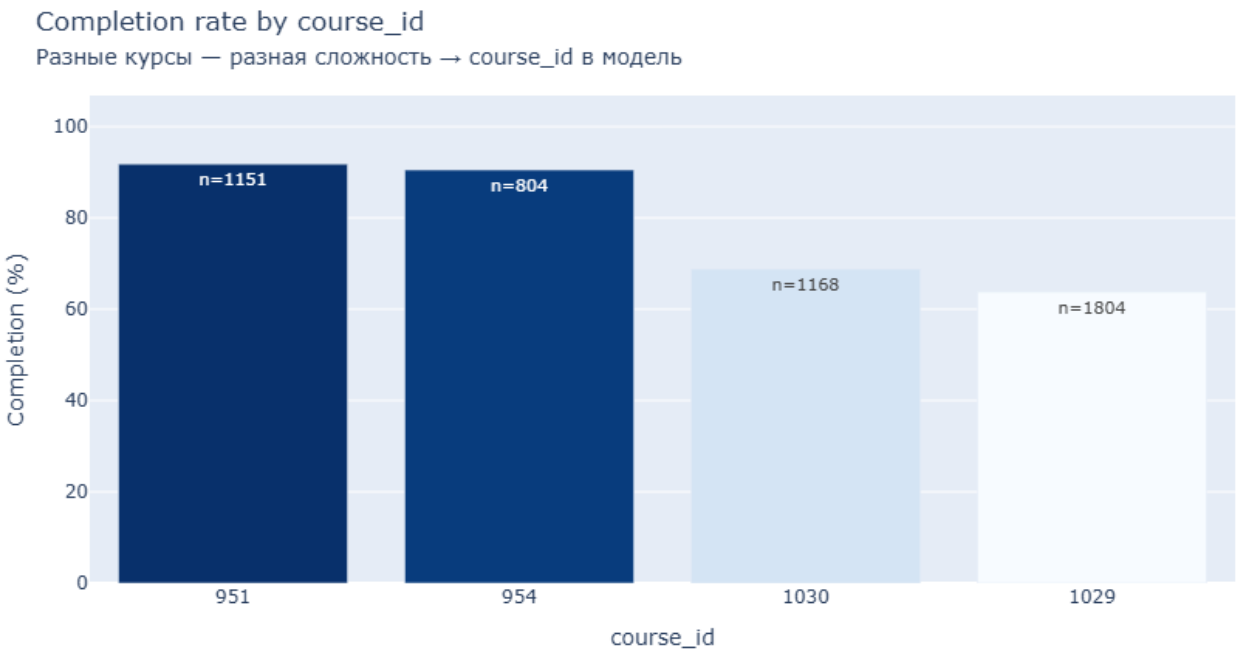

Для разных курсов наблюдается разный уровень успешного завершения. Это означает, что вероятность completion зависит не только от поведения пользователя, но и от характеристик самого курса.

H3. Интерпретация course-level эффекта

По course-level признакам можно сделать осторожный вывод:

- более высокая плотность заданий может быть связана с более низким completion;
- особенно это касается обязательных заданий;
- но этот вывод ограничен небольшим числом курсов в выборке.

То есть это не окончательная истина, а скорее сильная рабочая гипотеза для методистов.

H4. Timezone как сегментационный фактор

Гипотеза H4: timezone может быть статистически связан с completion, но остаётся скорее сегментационным, чем причинным фактором.

Здесь проверялось:

- есть ли различия completion между timezones;
- стоит ли использовать этот признак как слабый контекст в модели и дашборде.

Важно: этот блок не претендует на причинную интерпретацию, а скорее помогает в сегментации аудитории.

H4. Completion rate by timezone

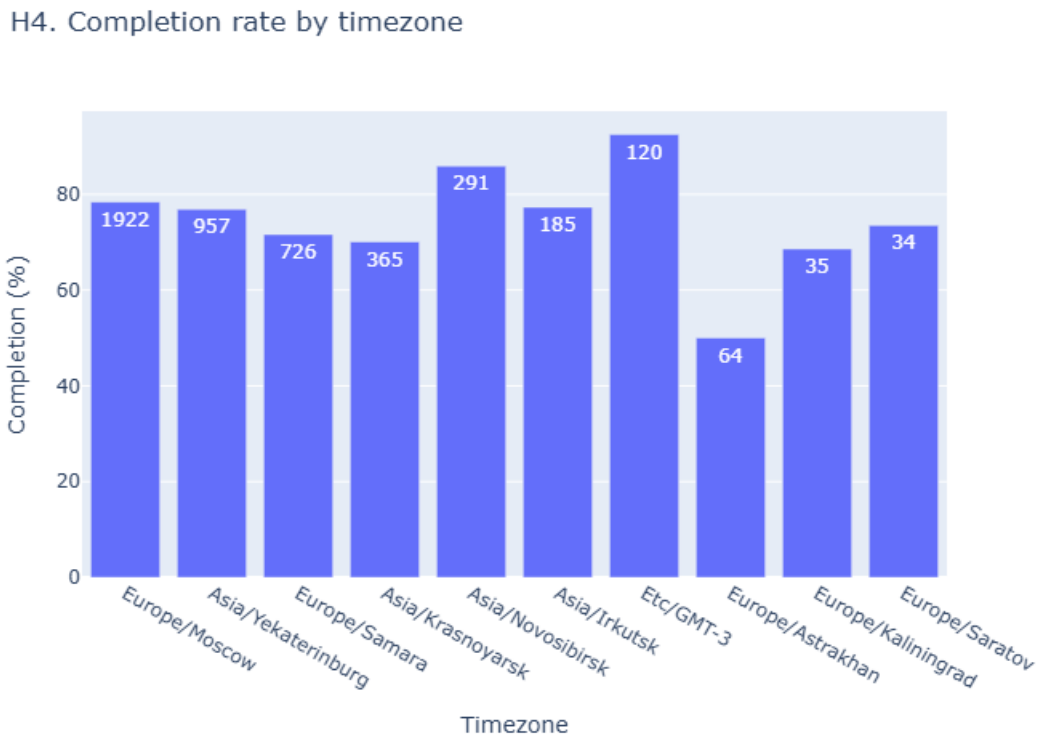

Timezone может давать статистический сигнал, но основной драйвер риска всё равно лежит в поведенческих признаках.

H5. Качество важно даже среди активных

Гипотеза H5: даже среди уже активных студентов качество выполнения остаётся важным сигналом completion.

Проверялись:

- `answer_solved_share`
- `training_mark_mean`

Это позволяет ответить на более тонкий вопрос: если студент уже работает, можно ли по качеству его работы заранее увидеть риск?

H5. Quality among active students

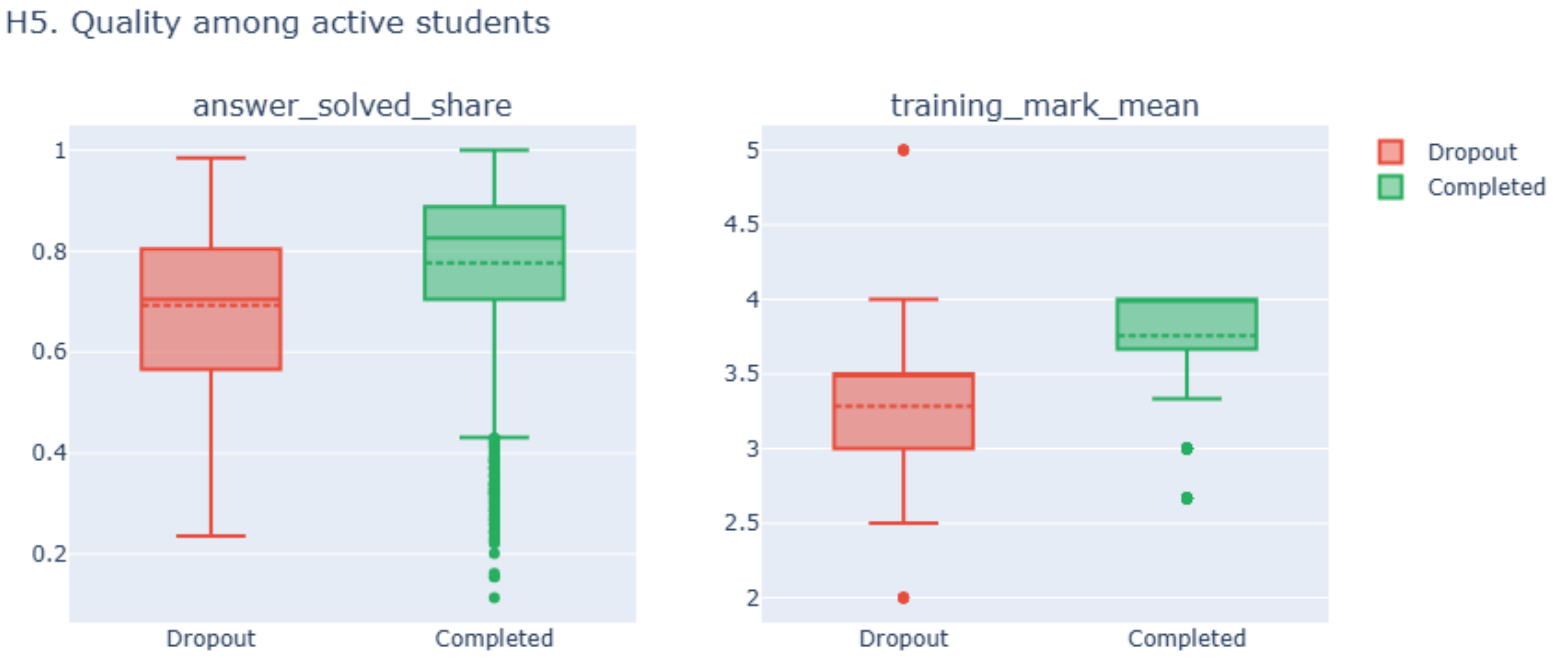

Даже среди активных пользователей качество выполнения продолжает различать completed и dropout. Это подтверждает, что риск связан не только с вовлечением, но и с академической сложностью.

H6. Какой блок признаков даёт основной сигнал

На последнем этапе EDA были построены подмодели на разных блоках признаков:

- только пользовательские признаки;
- только ранние признаки;
- только признаки ответов;
- только training-признаки;
- только course-level признаки;
- объединённые поведенческие признаки;
- полный отобранный набор.

Этот шаг нужен был для ответа на главный методический вопрос: какая часть признаков реально несёт основной предиктивный сигнал.

H6. ROC-AUC по блокам признаков

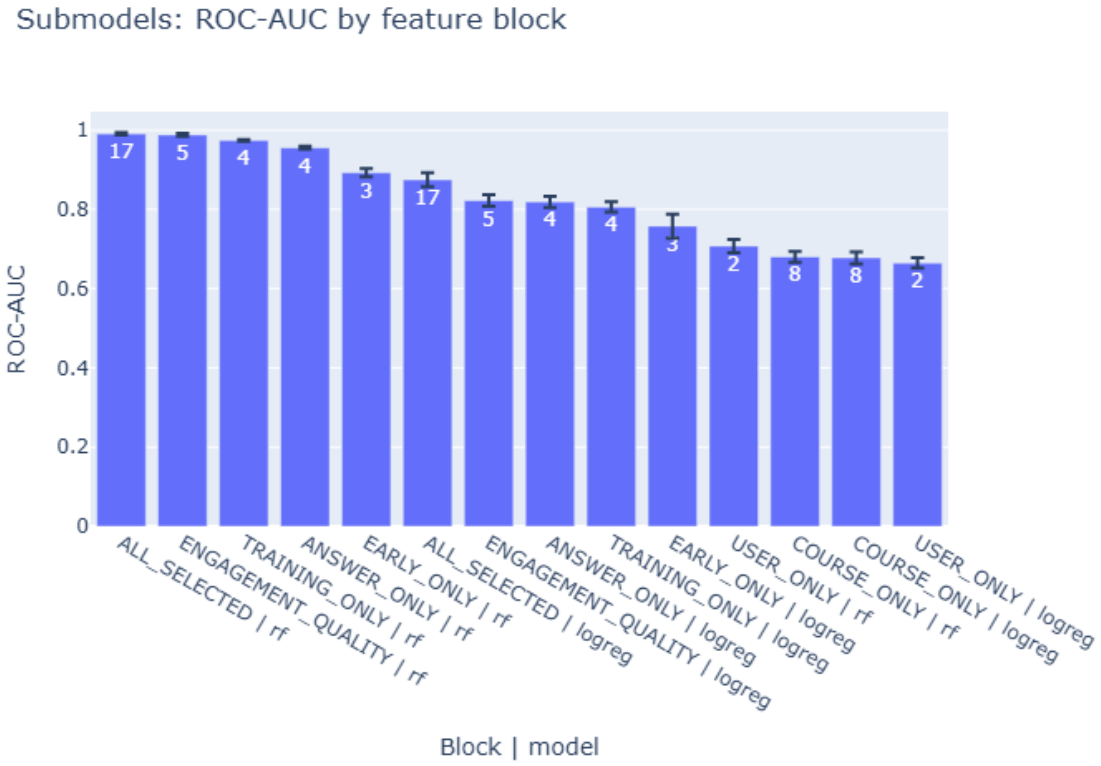

Сравнение подмоделей показывает, что главный сигнал дают поведенческие блоки, тогда как user-only и course-only признаки заметно слабее.

Промежуточный итог после гипотез

После гипотезного этапа картина выглядит так:

- survivor bias подтверждён;
- ранний старт и ранняя активность дают сильный сигнал;
- качество выполнения даёт дополнительный, самостоятельный вклад;
- нагрузка курса может влиять на completion, но вывод ограничен размером выборки;
- timezone полезен как сегментационный контекст;
- основной предиктивный вклад дают именно поведенческие признаки.

То есть EDA здесь дал не просто набор графиков, а осмысленную схему отбора честных признаков и интерпретируемых гипотез.

Распределение ключевых признаков

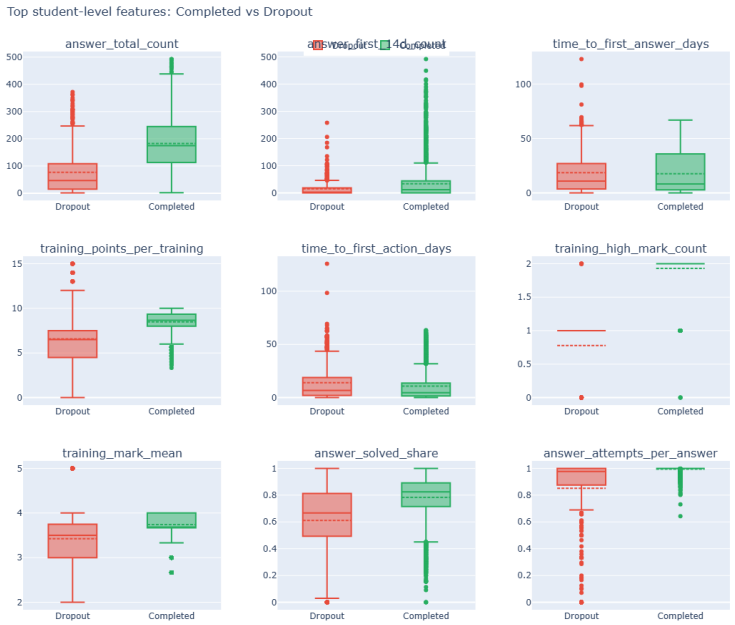

Распределения по top student-level признакам показывают, что завершившие модуль пользователи раньше включаются в работу и в среднем активнее взаимодействуют с учебными задачами.

Связь признаков с целевой переменной

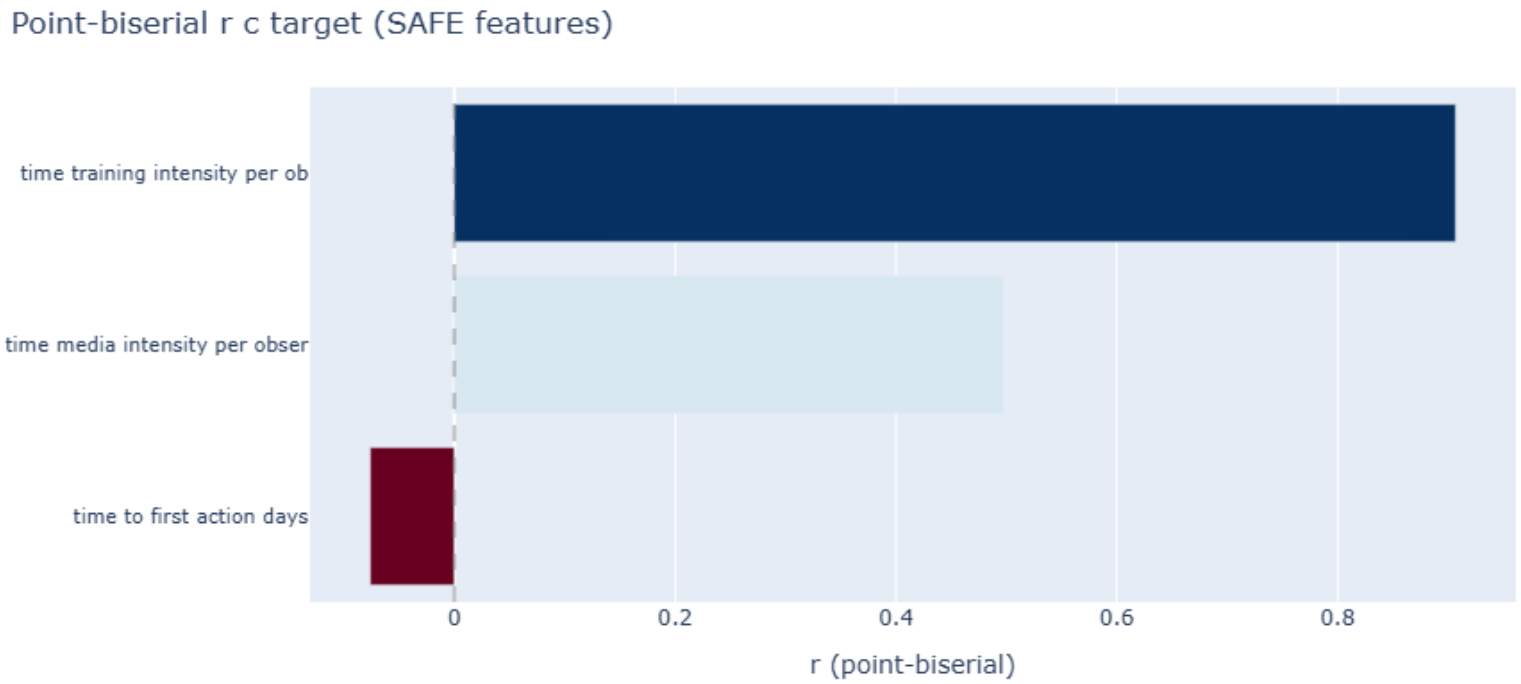

Point-biserial correlation использовалась как дополнительный способ ранжирования признаков. Она подтверждает, что ряд выбранных характеристик действительно несёт различающий сигнал.

Почему первая модель выглядела слишком хорошо

После гипотезного этапа была построена первая сильная модель на широком наборе признаков.

Однако почти идеальные метрики оказались не поводом для радости, а поводом для проверки постановки.

Слишком высокое качество в churn-задаче обычно означает одно из трёх:

- temporal leakage;
- использование пропусков как shortcut;
- чрезмерную близость признаков к финальному исходу.

Именно поэтому следующим шагом стал переход к более строгой и честной leakage-free постановке.

CatBoost baseline

После hypothesis-driven EDA была построена сильная baseline-модель на итоговом отобранном наборе признаков.

Эта модель использовалась не как финальный продукт, а как диагностический инструмент:

- проверить, насколько сильный суммарный сигнал вообще содержится в данных;
- посмотреть на важности признаков;
- выявить потенциальные признаки leakage.

Именно на этом этапе стало видно, что слишком высокое качество не стоит сразу интерпретировать как реальную переносимую предсказательную силу.

CatBoost feature importance

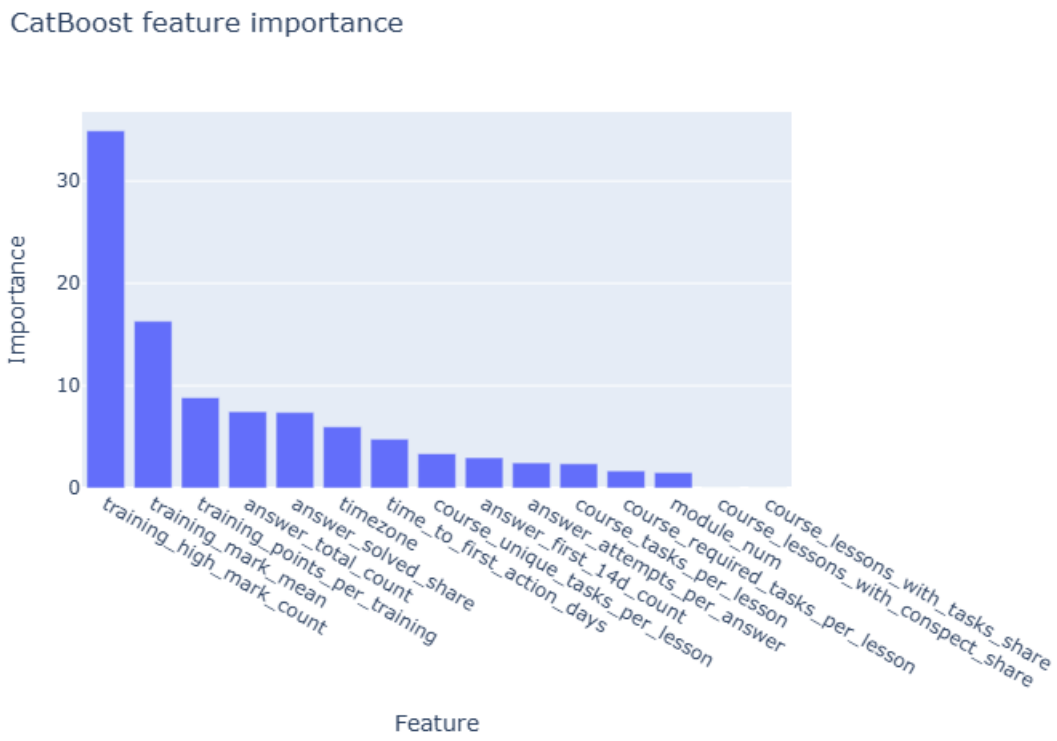

Важности baseline-модели полезны как диагностика, но именно они и показывают, что часть “сильных” признаков слишком близка к исходу обучения.

Почему это признак leakage

Подозрительно высокое качество baseline-модели интерпретировалось так:

- в модель могли попасть признаки, агрегированные по всему курсу;
- модель могла использовать сам факт отсутствия активности как shortcut;
- часть признаков была слишком близка к post-outcome информации.

Именно поэтому после “объясняющей” модели был сделан более честный шаг:

- использовать только ранние признаки;
- обучаться на $M1$;
- тестироваться на $M2$;
- не использовать спорные признаки и лишний контекст.

Leakage-free ранняя модель

Следующий этап — честная ранняя модель риска.

Её постановка была принципиально строже:

- используем только признаки, доступные на раннем горизонте;
- явно кодируем missingness через отдельные флаги;
- обучаемся на $M1$;
- тестируемся на $M2$;
- убираем full-course performance-признаки;
- не опираемся на спорные post-outcome сигналы.

Такая модель хуже по числу метрик, но значительно честнее по смыслу.

Leakage-free важности признаков

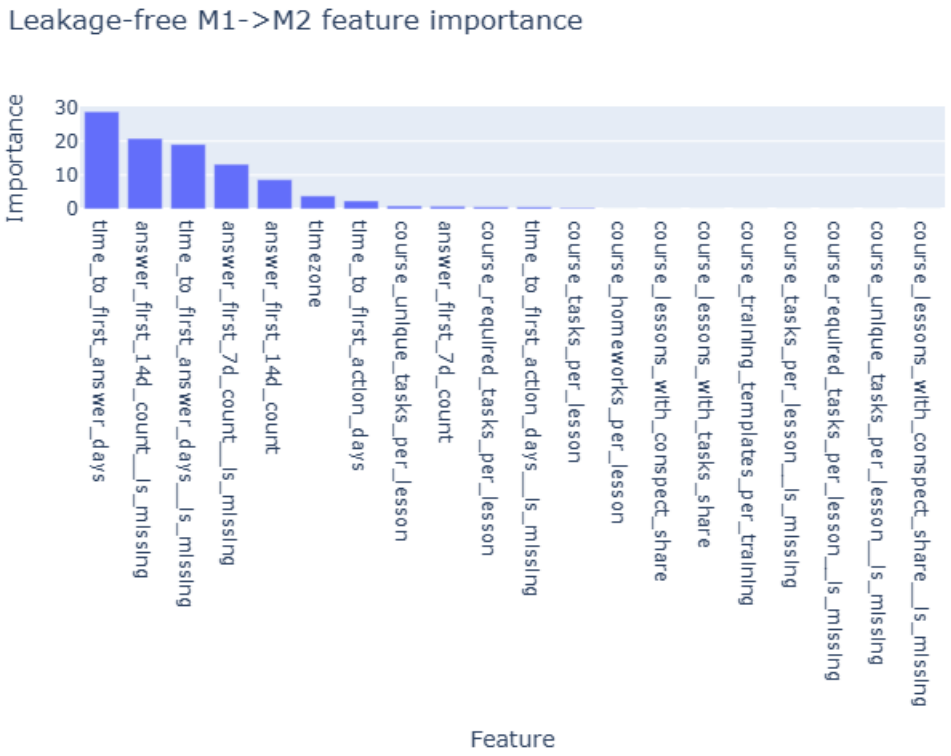

Leakage-free M1->M2 feature importance

После очистки постановки главный вклад начинают давать именно ранние признаки поведения, а не агрегаты, накопленные за весь курс.

Сравнение двух leakage-free версий

Чтобы сделать постановку ещё строже, сравнивались две версии ранней модели:

- версия A — с более широким набором ранних признаков;
- версия B — без признака `time_to_first_answer_days`, чтобы проверить устойчивость сигнала.

Результат сравнения:

- Version A: ROC-AUC = 0.8251, PR-AUC = 0.9697, BAL-ACC = 0.7790;
- Version B: ROC-AUC = 0.7799, PR-AUC = 0.9638, BAL-ACC = 0.7266.

Следовательно, выбранная leakage-free модель — **A_with_first_answer_days**.

Выбранная честная ранняя модель

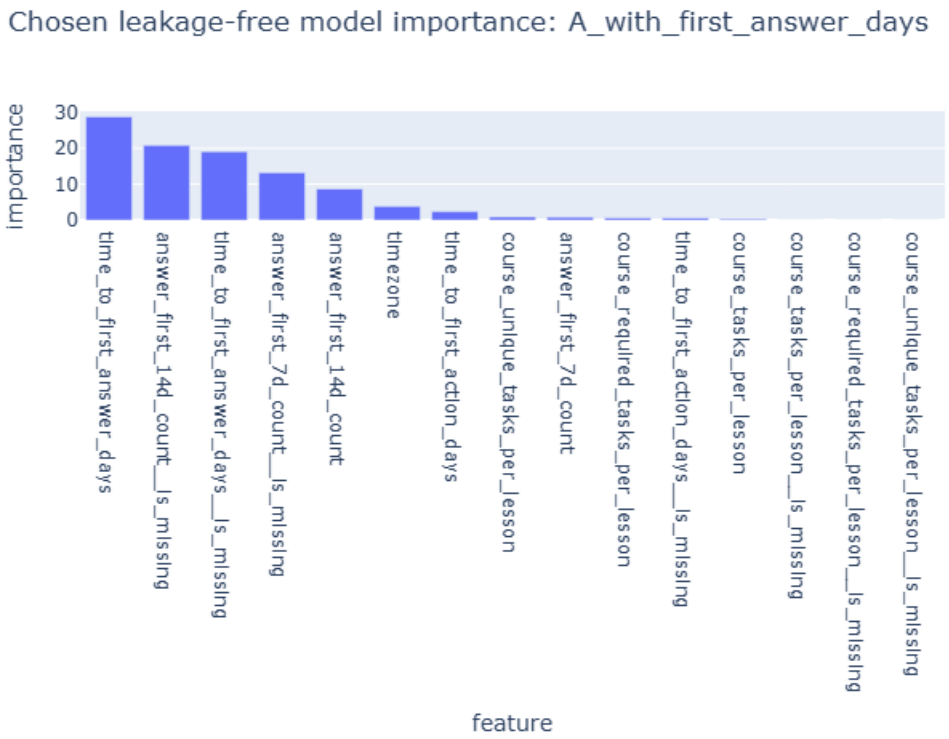

Итоговая leakage-free модель показывает, какие ранние признаки реально остаются значимыми после удаления спорных full-course сигналов.

SHAP для честной ранней модели

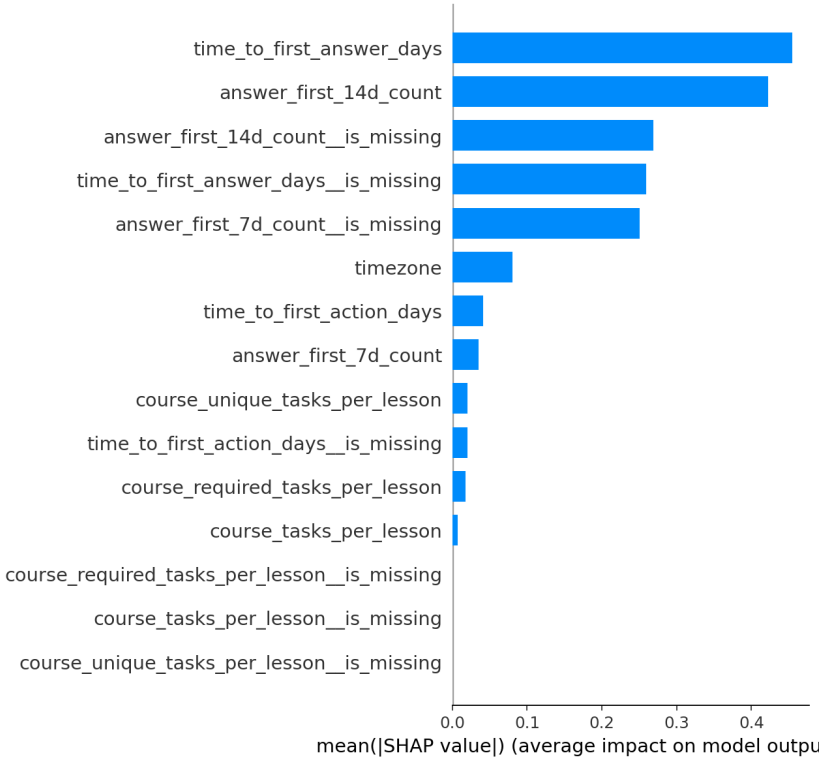

SHAP нужен здесь не для красоты, а для дополнительной проверки: действительно ли модель опирается на осмысленные ранние факторы риска, а не на технические артефакты.

Risk groups

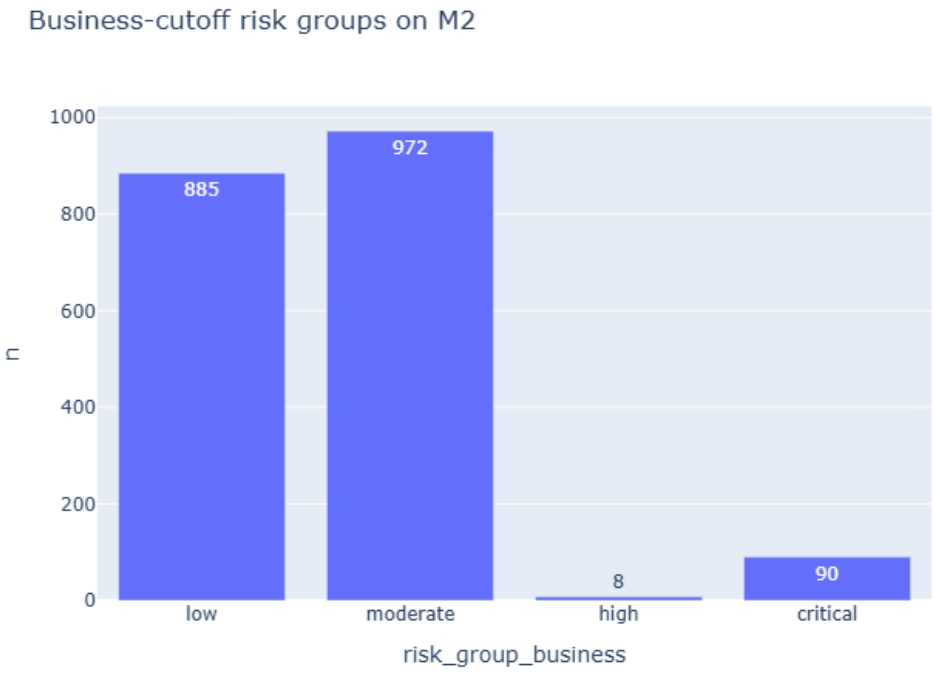

Разбиение на risk groups переводит прогноз из исследовательского формата в практический: студентов можно сегментировать по уровню риска и назначать разные сценарии сопровождения.

Что мы поняли про механику оттока

По итогам EDA и строгой leakage-free постановки можно выделить несколько ключевых механизмов:

- главный риск-сигнал — отсутствие входа в учебный ритм;
- второй механизм — вовлечённость без достаточного качества выполнения;
- course-level нагрузка может усиливать риск, но этот вывод пока ограничен по масштабу данных;
- профиль пользователя и сегментационные признаки полезны, но вторичны по сравнению с поведением.

Именно поэтому раннее учебное поведение становится главным объектом для интервенции.

Практические рекомендации для тьюторов

Результаты проекта показывают, что основной риск оттока проявляется уже на раннем этапе обучения.

Для тьюторов это означает следующее:

- отдельного внимания требуют студенты, которые поздно начинают активность;
- низкое число ответов в первые 7–14 дней можно использовать как ранний тревожный сигнал;
- нужно различать два сценария риска:
  - студент не включился в работу;
  - студент включился, но не справляется.

Эти два случая требуют разных сценариев сопровождения.

Практические рекомендации для методистов

По итогам гипотезного этапа есть основания считать, что плотность учебной нагрузки может быть связана с completion.

Это означает, что методистам стоит отдельно проверять:

- количество задач на урок;
- долю обязательных заданий;
- сложность входа в курс на первых неделях.

Даже если эти эффекты пока ограничены числом курсов в выборке, они важны как направление для последующей проверки и возможной корректировки структуры курса.

Бизнес-итог

Основной вывод проекта состоит в том, что риск оттока можно выявлять на раннем горизонте.

Это открывает три практических сценария:

- ранний скоринг студентов группы риска;
- сегментация риска по типу проблемы;
- приоритизация сопровождения со стороны тьюторов и методистов.

При этом модель должна оставаться методически честной: нужно опираться только на признаки, доступные в момент прогноза, и не использовать post-outcome сигналы.

Ограничения исследования

У текущего исследования есть несколько важных ограничений:

- размеченная выборка существенно уже полного массива данных;
- часть разумных признаков не раскрылась из-за слабой вариативности labeled-среза;
- course-level выводы ограничены небольшим числом курсов;
- часть сильных baseline-результатов пришлось переосмыслить из-за риска leakage.

Это не отменяет выводов проекта, но задаёт правильные границы их интерпретации.

Что можно улучшить дальше

Следующие логичные шаги:

- расширить объем и вариативность размеченных данных;
- отдельно проверить признаки, отброшенные на текущем labeled-срезе;
- валидировать course-level гипотезы на большем числе курсов;
- доработать risk groups под практический workflow тьюторов;
- перевести модель в формат регулярного раннего мониторинга.

На более широких данных модель можно сделать не только точнее, но и содержательно богаче.

Финальный вывод

Данные и постановка.

В рамках проекта были использованы выборки

$$N_{\text{train}} = 4927, \quad N_{\text{infer}} = 1785, \quad d = 453.$$

После EDA и feature selection исходное пространство признаков было сокращено до компактного интерпретируемого набора. При этом главный сигнал оказался сосредоточен в поведенческих признаках студента, тогда как user-level и course-level факторы играют скорее контекстную роль.

Главный методический результат.

Первая сильная CatBoost-модель дала почти идеальные метрики:

$$\text{ROC-AUC} = 0.9985, \quad \text{PR-AUC} = 0.9995, \quad \text{BAL-ACC} = 0.9795.$$

Однако такой результат оказался не честным итогом моделирования, а индикатором leakage. В модель попадали признаки, агрегированные по всему модулю, а также missingness-структура, слишком близкая к самому исходу обучения.

Финальный вывод

Что показала честная leakage-free постановка.
После удаления post-outcome признаков, явного кодирования пропусков и перехода к схеме train on $M1 \to$ test on $M2$ получено существенно более реалистичное качество:

$$\text{ROC-AUC} = 0.8251, \quad \text{PR-AUC} = 0.9697, \quad \text{BAL-ACC} = 0.7790.$$

Это означает, что прежняя почти идеальная модель действительно была завышена из-за leakage, но при этом реальный переносимый ранний сигнал всё равно сохраняется.

Главный аналитический вывод.
Наиболее устойчивыми драйверами риска оказались признаки раннего входа в учебный ритм:

- низкий `answer_first_14d_count`;
- поздний `time_to_first_action_days`;
- сильный вклад `time_to_first_answer_days`;
- отсутствие ранних ответов как отдельный наблюдаемый сигнал риска.

Финальный вывод

Структура риска.

Основной механизм оттока связан не столько с профилем студента, сколько с тем, успел ли он вообще войти в учебный ритм в первые дни и недели. По итогам исследования риск имеет как минимум два разных сценария:

- **low activity** — студент не вовлёкся;
- **high activity + low quality** — студент вовлёкся, но не справляется.

Такое разделение важно не только аналитически, но и практически: разные группы риска требуют разных интервенций.

Роль course-level и user-level признаков.

Course-level признаки содержат слабый или умеренный сигнал. В частности,

`course_tasks_per_lesson`, `course_required_tasks_per_lesson`, `course`

показывают сильную отрицательную связь с completion-rate: $r \approx -0.864$. Но этот вывод нужно интерпретировать осторожно, поскольку он основан всего на четырёх курсах. Аналогично, `timezone` статистически связан с completion, но остаётся скорее сегментационным, чем причинным фактором.

Финальный вывод

Практический бизнес-результат.

Главный прикладной итог проекта состоит в том, что риск оттока действительно можно выявлять уже в первые 1–2 недели обучения. Это делает возможными:

- ранний скоринг студентов группы риска;
- триггеры по отсутствию активности и малому числу решений;
- разделение кейсов на “не вовлёкся” и “не справляется”;
- приоритизацию сопровождения со стороны тьюторов;
- отдельную проверку course-load гипотез со стороны методистов.

Итоговый вывод.

Исследование показало, что даже после удаления leakage и перехода к строгой постановке модель сохраняет устойчивый переносимый сигнал. Следовательно, компания действительно может строить методически корректную систему раннего выявления риска оттока.

Итог

В проекте получился полный исследовательский и прикладной pipeline:

- сборка master-table;
- feature engineering;
- поэтапная борьба с leakage;
- hypothesis-driven EDA;
- сравнение блоков признаков;
- переход от “слишком хорошей” модели к честной leakage-free постановке;
- формирование практических рекомендаций для бизнеса.

Главный результат: ранний риск оттока можно корректно выявлять